




تمرین یکم شبکه‌های عصبی

تاریخ بارگذاری تمرین: ۱۴۰۴/۱۰/۰۷

تاریخ تحویل تمرین: ۱۴۰۴/۱۱/۱۱



۱ برنامه‌نویسی

غرابی جادویی به شرکت OpenAI رفته و تمامی جی‌پی‌یوهای H100 این شرکت ناپدید شده‌اند. حال سم آلتمن^۲ از شما می‌خواهد تا با کار روی شبکه‌های عصبی هم‌گشتی^۳ به او کمک کنید. در این پروژه سعی می‌کنید تا لایه‌ی هم‌گشتی جدیدی برای دسته‌بندی تصاویر گلوبول‌های قرمز پیاده‌سازی نمایید که از پیچیدگی محاسباتی کم‌تری برخوردار باشد.



شکل ۱: غراب در حال دزدی جی‌پی‌یوها!

در سال‌های گذشته، تمرکز بیش‌تری روی شبکه‌هایی با هدف اجرا روی سیستم‌های ضعیف‌تر و با محاسبات سریع‌تر اتفاق افتاده است [۱]. معمولاً روش‌های پیشنهاد موجود در یکی از دسته‌های زیر قرار می‌گیرند:

- تقطیر دانش^۴ که در آن با بهره‌گیری از عنصر مقایسه، یک شبکه‌ی کوچک‌تر براساس شبکه‌ی بزرگ‌تر با تعداد پارامتر بیش‌تر آموزش می‌بیند.
- کوانتیزاسیون^۵، در این فرایند معمولاً مباحثی نظیر تعداد بیت‌های وزن‌های ذخیره‌شده مورد بررسی قرار می‌گیرد. در واقع با کاهش نوع داده^۶ به نمونه‌هایی که رنج کم‌تری دارند، تعداد محاسبات و فضای ذخیره‌سازی کم‌تر می‌گردد. باید توجه داشت که این امر می‌تواند باعث کاهش معیارهای مدل مورد نظر شود.
- هرس^۷ در این ایده، برخی از یال‌های شبکه‌ی عصبی براساس معیاری از پیش تعیین شده حذف می‌شوند. در واقع ایده‌ی اصلی آن از این نظریه می‌آید که در دل شبکه‌های عصبی بزرگ می‌توان شبکه‌های عصبی کوچک‌تری یافت که همان عمل‌کرد مناسب شبکه‌های بزرگ‌تر را داشته باشد.

^۱ GPU

^۲ Sam Altman

^۳ Convolutional neural network

^۴ Knowledge distillation

^۵ Quantization

^۶ Data type

^۷ Pruning

به جز روش‌های نام برده شده در این قسمت، راه دیگری نیز وجود دارد. طراحی شبکه و لایه‌های جدیدتر که از حیث محاسباتی و استفاده حافظه از روش‌های پیشین بهتر عمل کنند. یک لایه‌ی هم‌گشتی را در نظر بگیرید. این لایه مجموعه‌ای از داده‌ها با ابعاد $R^{B \times C_{in} \times H \times W}$ را دریافت می‌کند، و مجموعه داده‌ای در ابعاد $R^{B \times C_{out} \times H_{out} \times W_{out}}$ را در خروجی ارائه می‌دهد. در این نمایش B تعداد نمونه داده‌ها در یک mini batch، H و W به ترتیب طول و عرض، و C تعداد ویژگی‌ها را نمایش می‌دهد.^۹ به این ترتیب ماتریس وزنی یک لایه‌ی هم‌گشتی برای یک کرنل^{۱۰} می‌بایست در فضایی با ابعادی برابر با $R^{C_{out} \times C_{in} \times K \times K}$ قرار خواهد داشت، که در آن K اندازه کرنل را مشخص می‌کند.

- تعداد پارامترهای آموزش‌پذیر در چنین لایه‌ای چقدر خواهد بود؟
- در صورتی که این لایه با یک لایه‌ی خطی جایگزین گردد، تعداد پارامترهای آموزش‌پذیر چقدر می‌شود؟
- توضیح دهید چرا کرنل لایه‌ی هم‌گشتی معمولاً مربعی است؟

• تحقیق کنید آیا اندازه کرنل می‌تواند عدد حقیقی ($K \in R$) باشد؟ (اختیاری)

از نقطه نظر بهینه بودن محاسبات دو متریک FLOPS و FLOPs مطرح می‌گردد.^{۱۱} در این دو متریک، واژه FLOP بیان‌گر Floating-point Operation می‌باشد. تفاوت این دو سرواژه براساس تعداد عملیات‌های ممیز شناور به صورت کلی برای یک تسک و در یک ثانیه است. به بیان دیگر FLOPS نشان‌دهنده‌ی تعداد عملیات‌های ممیز شناور در یک ثانیه (Floating-point Operations per Second) و FLOPs نشان‌دهنده‌ی تعداد کل عملیات‌های ممیز شناور (Floating-point Operations) برای یک تسک مثلاً کل مدل است. باید توجه داشت که FLOPS با در نظر گرفتن یک سخت‌افزار محاسبه می‌گردد، هر چند مقدار نهایی در واقعیت آن از مقداری که تولیدکننده سخت‌افزار گزارش کرده است می‌تواند متفاوت باشد که به صورت خاص به عنوان achieved FLOPS مطرح می‌گردد.^{۱۲} براساس این دو، متریک تأخیر^{۱۳} تعریف می‌شود:

$$\text{Latency} = \frac{\text{FLOPs}}{\text{FLOPS}} \quad (1)$$

واحد تأخیر به ثانیه خواهد بود و نشان‌دهنده‌ی زمان لازم برای انجام محاسبات روی یک سخت‌افزار مشخص است (به کوچک و بزرگ بودن s صورت و مخرج توجه نمایید).

- مشخص کنید، چرا در این متریک FLOPs در صورت و FLOPS در مخرج قرار گرفته است؟

• در صورتی که یک عملیات جمع، یک FLOP بخواهد و عملیات ضرب و جمع با هم (نظیر $x \times y + z$) دو FLOP نیاز داشته باشد، آنگاه FLOPs یک لایه‌ی هم‌گشتی چقدر خواهد بود؟ فرض کنید که طول و عرض تصویر خروجی با طول و عرض تصویر ورودی برابر باشد. (اختیاری)

در شبکه‌هایی نظیر MobileNet [۲] و GhostNet برای بهبود محاسبات از ترکیب لایه‌ی هم‌گشتی عمقی^{۱۴} و نقطه‌ای^{۱۵} استفاده می‌شود. کرنل لایه‌ی هم‌گشتی عمقی در $R^{C_{out} \times 1 \times K \times K}$ تعریف می‌شود و معمولاً تعداد ویژگی‌های خروجی برابر با تعداد ویژگی‌های ورودی در نظر گرفته می‌شود ($C_{in} = C_{out}$). به این ترتیب برخلاف لایه‌ی هم‌گشتی معمول که هر بُعد ویژگی خروجی (C_{out}) حاصل ترکیب تمامی ویژگی‌های ورودی است، در این حالت هر ویژگی خروجی براساس یک ویژگی ورودی محاسبه شده است. به همین خاطر است که بعد ویژگی‌های ورودی و خروجی برابر هم در نظر گرفته شده‌اند. پس از لایه‌ی عمقی، معمولاً یک لایه‌ی هم‌گشتی نقطه‌ای استفاده می‌شود که کرنل آن در فضای $R^{C_{out} \times C_{in} \times 1 \times 1}$ قرار دارد. به این ترتیب این لایه به صورت مستقل روی هر پیکسل ورودی عمل می‌کند. این لایه کمک می‌کند تا بعد ویژگی‌ها افزایش یابد و نتایج شبکه بهبود یابد [۲].

^۸Channel

^۹ در ادبیات معمول شبکه‌های عصبی، channel را باتوجه به پیشینه‌ی آن کانال ترجمه می‌کنند. در این متن با هدف پررنگ‌تر کردن مفهوم این بُعد در شبکه‌های عصبی هم‌گشتی، این واژه در قالب ویژگی ترجمه شده است. هر چند این ترجمه نیز مشکلات خود را داراست نظیر عدم تمایز قائل شدن بین واژه feature و channel.

^{۱۰}Kernel

^{۱۱} نام‌گذاری آن‌ها نظیر سایر نام‌گذاری‌های دنیای هوش مصنوعی مناسب نیستند و شاید در برخورد اولیه گیج کننده باشند. به طور معمول انتظار می‌رود s پایانی در FLOPS نوشته نشود چرا که s به عنوان علامت جمع واژه operations آورده شده است و در مورد FLOPS نیز این s جمع وجود دارد.

^{۱۲} در ادامه متن و برای سادگی نگارش ممکن است گزارش این وابستگی به سخت‌افزار خاص نادیده گرفته شود.

^{۱۳}Latency

^{۱۴}Depth-wise

^{۱۵}Point-wise

• توضیح دهید لایه‌ی هم‌گشتی گروهی^{۱۶} چه تفاوتی از لایه‌ی عمقی دارد؟

• توضیح دهید چگونه با تغییر یک لایه‌ی هم‌گشتی معمول به ترکیبی از دولایه‌ی هم‌گشتی عمقی و نقطه‌ای پشت‌سر هم، پیچیدگی محاسباتی شبکه کاهش می‌یابد؟ (نیازی به محاسبات دقیق نیست)


حال که مروری کلی و کوتاه بر بهینه‌سازی شبکه‌های عصبی (هم‌گشتی) صورت گرفت، یک شبکه هم‌گشتی بهبود یافته برای دسته‌بندی تصاویر طراحی می‌کنید. به صورت کلی می‌توان شبکه‌ای را مناسب دانست که نه تنها تعداد کل عملیات‌های ممیز شناور (FLOPs) آن کم باشد، بلکه بالاترین نرخ FLOPs را داشته باشد. یکی از مشکلاتی که شبکه‌های معمول که از لایه‌های عمقی یاد شده استفاده می‌کنند این است که FLOPs خوبی ندارند. این مسئله گاهی از نرخ دسترسی به حافظه ناشی می‌شود. از سمتی لایه‌های هم‌گشتی در ابعاد ویژگی مختلف، الگوهای یکسانی را نمایش می‌دهند. به این معنا که در یک لایه‌ی میانی اگر نگاشت ویژگی یک شبکه هم‌گشتی به تصویر کشیده شود، الگوهای یکسانی بین بدهای ویژگی مختلف دیده می‌شود. با توجه به این اشتراک می‌توان لایه‌ی هم‌گشتی طراحی کرد که عمل‌کرد بهتری از خود نمایش دهد. در این راستا آزمایش‌های زیر طراحی شده‌اند.

۱.۱ مجموعه داده

مجموعه داده‌ی مالاریا^{۱۷} را در نظر بگیرید [۳]. این مجموعه داده را از طریق **لینک** می‌توانید دریافت نمایید. از طریق کلاس‌های Dataset و Dataloader موجود در پایتورچ یک دیتاست براساس داده‌ی دریافتی ایجاد نمایید. این مجموعه داده شامل ۲۷,۵۵۸ تصویر گلبول قرمز^{۱۸} می‌باشد که به دو دسته‌ی سالم (uninfected) و انگلی (parasitized) تقسیم می‌شود. نام علمی این انگل پلاسمودیوم فالسیپاروم^{۱۹} می‌باشد که عامل مالاریاست. تصاویر را به اندازه‌ی ۲۸ در ۲۸ پیکسل تغییر دهید و مقادیر عددی پیکسل‌ها را به بازه‌ی صفر تا یک ببرید. از هر دسته، سه نمونه داده را نمایش دهید. آیا این مجموعه داده بالانس است؟

۲.۱ مدل طراحی شده

یک شبکه‌ی عصبی هم‌گشتی متشکل از چهار لایه‌ی هم‌گشتی را در نظر بگیرید. پس از این چهار لایه یک لایه‌ی pooling قرار می‌گیرد. سپس خروجی آن به یک لایه خطی با تابع فعال‌سازی سیگنوییدی داده می‌شود که وظیفه‌ی دسته‌بندی تصاویر به دو دسته در نظر گرفته شده را دارد. ساختار کلی شبکه در شکل (۲) نمایش داده شده است. ابتدا این شبکه را در پایتورچ پیاده‌سازی نمایید. توجه داشته باشید که سایز کرنل تمامی لایه‌های هم‌گشتی ۳ خواهد بود.



شکل ۲: ساختار کلی مدل هم‌گشتی

تابع خطا آنتروپی متقاطع^{۲۰} و بهینه‌ساز^{۲۱} RMSprop با نرخ یادگیری 0.001 خواهد بود.

^{۱۶}Group-wise convolutional layer

^{۱۷}Malaria

^{۱۸}Red blood cell

^{۱۹}Plasmodium falciparum

^{۲۰}Cross-entropy

^{۲۱}Optimizer

۱.۲.۱ شبکه با لایه‌ی هم‌گشتی خاص

همان‌طور که پیش‌تر اشاره شده روش‌های مختلفی برای کاهش هزینه‌های لایه‌های هم‌گشتی پیشنهاد شده‌اند. در این بخش یک لایه‌ی هم‌گشتی خاص با هدف کاهش هزینه‌های محاسباتی و حافظه‌ای طراحی می‌گردد. شبکه‌ی قبلی را در نظر بگیرید. لایه‌ی هم‌گشتی چهارم را در نظر بگیرید که تعداد ویژگی ورودی و خروجی برابر با ۳۲ دارد. حال به جای لایه‌ی چهارم، لایه‌ی هم‌گشتی خاص را قرار دهید. این لایه، ورودی $F \in R^{32 \times h \times w}$ را که دریافت می‌کند، از بُعد ویژگی به دو قسمت $F_1 \in R^{16 \times h \times w}$ و $F_2 \in R^{16 \times h \times w}$ تقسیم می‌نماید. سپس صرفاً یک لایه‌ی هم‌گشتی معمولی (این لایه جدید و فارغ از لایه‌های پیشین است و به عنوان وزن‌های آموزش‌پذیر لایه‌ی خاص چهارم در نظر گرفته می‌شود) با تعداد ویژگی ورودی ۱۶ و خروجی ۱۶ به گونه‌ای روی F_1 اعمال می‌گردد که طول و عرض تانسور خروجی ثابت باقی بماند. سپس در گام بعدی خروجی این لایه در راستای بُعد ویژگی‌ها در کنار F_2 قرار می‌گیرد. به بیان دیگر در این لایه صرفاً یک لایه‌ی هم‌گشتی روی ۱۶ ویژگی ابتدایی اعمال می‌گردد. سایر لایه‌ها تغییری نمی‌کنند اما در صورتی که این ساختار باعث تغییر در سایر ابعاد شده است، می‌بایست تغییرات را اعمال نمایید. این شبکه را نیز مانند شبکه قبلی آموزش و مورد آزمون قرار دهید.

اختیاری پس از لایه‌ی هم‌گشتی خاص، یک لایه‌ی هم‌گشتی نقطه‌ای قرار دهید سپس آن را در اختیار دسته‌بند قرار دهید. تنظیم پارامترهای شبکه با شما خواهد بود. نتایج این شبکه را نیز گزارش نمایید. آیا این تغییر باعث بهبود عمل‌کردی مدل شده است؟

۳.۱ آموزش

- مجموعه داده را به دو قسمت آموزش و آزمون تقسیم نمایید.
 - هر مدل را یک‌بار مورد آموزش و آزمون قرار دهید.
 - هر مدل می‌بایست با تعداد اپیاک^{۲۲} برابر با ۸ آموزش ببیند.
 - نمودارهای مرتبط به آموزش و آزمون را در tensorboard ذخیره نمایید.
 - متریک FLOPs برای هر دو مدل را گزارش نمایید.
- در گزارش به پرسش‌های زیر در رابطه با مدل با لایه‌ی هم‌گشتی خاص پاسخ دهید.
- با توجه به متن پرسش ارائه شده، چرا در لایه‌ی هم‌گشتی خاص، عملیات هم‌گشتی صرفاً روی بخش ابتدایی تانسور ورودی اعمال شد؟
 - از حیث تعداد پارامترهای آموزش‌پذیر این دو مدل چه تفاوتی نسبت به یکدیگر دارند؟

مراجع

- [1] G. Menghani, "Efficient deep learning: A survey on making deep learning models smaller, faster, and better," *ACM Computing Surveys*, vol.55, no.12, pp.1–37, 2023.
- [2] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "Mobilenetv2: Inverted residuals and linear bottlenecks," in *Proceedings of the IEEE conference on computer vision and pattern recognition*, pp.4510–4520, 2018.
- [3] S. Rajaraman, S. K. Antani, M. Poostchi, K. Silamut, M. A. Hossain, R. J. Maude, S. Jaeger, and G. R. Thoma, "Pre-trained convolutional neural networks as feature extractors toward improved malaria parasite detection in thin blood smear images," *PeerJ*, vol.6, p.e4568, 2018.

²²epoch