




تشخیص ناهنجاری

مقاله پایه : EfficientAD (WACV 2024)



محمد امین کیانی 4043644008

دانشجوی کارشناسی ارشد - هوش مصنوعی



• مسئله: تشخیص ناهنجاری در تصاویر صنعتی

- هدف: تشخیص قطعات معیوب/ناهنجار بدون داشتن نمونه‌های کافی از همه‌ی عیوب

- ورودی: فقط تصاویر سالم برای آموزش (unsupervised / one-class)

- خروجی: (۱) نمره ناهنجاری سطح تصویر (۲) نقشه مکان‌یابی عیب

- چالش: هم عیوب «موضعی» (خراش/آلودگی) و هم عیوب «منطقی» (چیدمان/کمبود قطعه)



• EfficientAD در یک نگاه

- معلم فریز شده: استخراج ویژگی‌های سریع (PDN)
- شاگرد: تقلید ویژگی‌های معلم فقط با تصاویر سالم
- خودرمزگذار سراسری: کمک به تشخیص ناهنجاری‌های «منطقی»/غیرموضعی
- نقشه ناهنجاری برابر است با اختلاف Teacher-Student (موضعی) + اختلاف AE-Student (سراسری)




Figure 2. Patch description network (PDN) architecture of EfficientAD-S. Applying it to an image in a fully convolutional manner yields all features in a single forward pass.



۱۰ اجزای کلیدی حل مشکلات روش‌های قبل

1) Hard Feature Mining

تمرکز آموزش شاگرد روی سخت‌ترین پیکسل/ویژگی‌ها تا از یادگیری سطحی و overfit جلوگیری شود.

2) Pretraining Penalty (OOD penalty)

با تصاویر غیرمرتبط (Imagenette/ImageNet) شاگرد را از تولید ویژگی‌های بزرگ روی داده‌های خارج از توزیع بازمی‌دارد.

3) Global Autoencoder

ضعف روش‌های موضعی در تشخیص ناهنجاری‌های منطقی را جبران می‌کند.

Schematic



$$\text{Anomaly Map} = 0.5 \cdot \text{map_ST} + 0.5 \cdot \text{map_AE}$$

$$\text{map_ST}: (\text{Teacher} - \text{Student})^2 \mid \text{map_AE}: (\text{AE} - \text{Student})^2$$

• دیتاست‌ها و معیارهای ارزیابی

حداقل روی ۲ دیتاست: MVtec AD و MVtec LOCO AD


MVtec AD

• 15 کلاس | ماسک‌های دقیق پیکسلی



MVtec LOCO AD

• 5 کلاس | ساختاری + منطقی



معیارها

تفکیک سالم/معیوب در سطح تصویر: Image AUROC

تفکیک پیکسل‌های عیب/سالم: Pixel AUROC

FPR ≤ 0.3 میانگین پوشش ناحیه عیب با محدودیت: AU-PRO@0.3



دانشکده مهندسی کامپیوتر

ارائه‌ی شبکه‌های عصبی عمیق

• پیاده‌سازی و صحت‌سنجی در Google Colab

(۱) کلون ریپو nelson1425/EfficientAD و دانلود وزن‌های Teacher (small/medium)

(۲) دانلود دیتاست‌ها از لینک‌های رسمی

(۳) اجرای efficientad_tb.py: آموزش Student+AE و تولید anomaly map برای test

(۴) ثبت lossها و متریک‌ها در TensorBoard (train + test) و ذخیره وزن‌ها

(۵) استخراج خروجی‌ها: final_metrics.json + anomaly_maps + weights_report.csv

Colab



TensorBoard




دانشکده مهندسی کامپیوتر

ارائه‌ی شبکه‌های عصبی عمیق

• نتایج باز تولید (Baseline)

Model :medium | train_steps: 70000, 7000, 2000, 1000 | penalty: True



MVTec AD (bottle)

Image AUROC: 99.92%

Pixel AUROC: 0.982

AU-PRO@0.3: 0.347

MVTec LOCO (breakfast_box)

Image AUROC: 84.05%

Pixel metrics: نیاز به ارزیابی اختصاصی ماسک‌ها

نکته: این نتایج میانگین کل دیتاست نیستند؛ فقط روی کلاس‌هایی که دانلود/اجرا شده‌اند.



• مشاهدات / محدودیت‌ها در بازتولید

- لینک‌های قدیمی mydrive منسوخ شده‌اند که روش بهتری وجود دارد اما دارای محدودیت: دانلود از صفحات رسمی MVtec و object-level

- دانلود کامل چندین گیگ دیتاست در Colab گاهی ناقص می‌شود پس به جای FULL، کلاس‌ها را جداگانه گرفتیم.

- در LOCO، ماسک‌ها و نام‌گذاری‌شان با MVtec AD فرق دارد پس ارزیابی pixel-level باید dataset-aware باشد.

- محاسبه AU-PRO دقیق روی کل پیکسل‌ها RAM زیادی می‌خواهد که راه‌حل: محاسبه disk- / streaming based

- TRAIN_STEPS=70000 برای همه کلاس‌ها زمان‌بر است پس نسخه‌ی QUICK را اجرا کردیم.



ایده جدید

مسئله‌ای که می‌خواهیم بهتر کنیم:

در LOCO، بخشی از ناهنجاری‌ها «منطقی» هستند؛ ترکیب ثابت 0.5/0.5 بین map_ST و map_AE که همیشه بهترین نیست.


ایده: ترکیب تطبیقی (Adaptive Fusion)

به جای وزن ثابت، یک وزن α را از «آمار نقشه‌ها» یا یک head بسیار سبک روی ویژگی‌های Teacher به دست می‌آوریم:

$$\text{score_map} = \alpha \cdot \text{map_ST} + (1-\alpha) \cdot \text{map_AE}$$

α بزرگ‌تر یعنی عیب‌های موضعی و کوچک‌تر یعنی عیب‌های منطقی

Adaptive Fusion



چرا نوآورانه و قابل پیاده‌سازی است؟

- بدون تغییر Teacher
- فقط چند خط تغییر در مرحله inference و یک head کوچک
- قابل تست مستقیم روی همان کلاس‌هایی که baseline اجرا شده‌اند



دانشکده مهندسی کامپیوتر

ارائه‌ی شبکه‌های عصبی عمیق

• پیاده‌سازی ایده

نتایج بهبود یافت.

```
final_metrics_dcc_ad.json - Notepad
File Edit Format View Help
{
  "dataset": "mvtec_ad",
  "subdataset": "bottle",
  "model_size": "medium",
  "train_steps": 1000,
  "pretrain_penalty": true,
  "tb_dir": "/content/outputs/efficientad_dcc_runs/trainings/mvtec_ad/bottle/tensorboard",
  "train_output_dir": "/content/outputs/efficientad_dcc_runs/trainings/mvtec_ad/bottle",
  "test_output_base":
"/content/outputs/efficientad_dcc_runs/anomaly_maps_base/mvtec_ad/bottle/test",
  "test_output_dcc": "/content/outputs/efficientad_dcc_runs/anomaly_maps_dcc/mvtec_ad/bottle/test",
  "final_image_auc_base": 96.58730158730158,
  "final_image_auc_dcc": 97.77777777777777,
  "dcc_enable": true,
  "dcc_k": 128,
  "dcc_pool": 2,
  "dcc_weight": 0.2
}
Ln 1, Col 1 100% Unix (LF) UTF-8

base_final_metrics_ad.json - Notepad
File Edit Format View Help
{
  "dataset": "mvtec_ad",
  "subdataset": "bottle",
  "model_size": "medium",
  "train_steps": 1000,
  "final_image_auc": 96.66666666666667,
  "tb_dir": "/content/outputs/efficientad_runs/trainings/mvtec_ad/bottle/tensorboard",
  "train_output_dir": "/content/outputs/efficientad_runs/trainings/mvtec_ad/bottle",
  "test_output_dir": "/content/outputs/efficientad_runs/anomaly_maps/mvtec_ad/bottle/test",
  "pretrain_penalty": true
}
Ln 11, Col 2 100% Unix (LF) UTF-8

final_metrics_dcc_loco.json - Notepad
File Edit Format View Help
{
  "dataset": "mvtec_loco",
  "subdataset": "breakfast_box",
  "model_size": "medium",
  "train_steps": 1000,
  "pretrain_penalty": true,
  "tb_dir": "/content/outputs/efficientad_dcc_runs/trainings/mvtec_loco/breakfast_box/tensorboard",
  "train_output_dir": "/content/outputs/efficientad_dcc_runs/trainings/mvtec_loco/breakfast_box",
  "test_output_base":
"/content/outputs/efficientad_dcc_runs/anomaly_maps_base/mvtec_loco/breakfast_box/test",
  "test_output_dcc":
"/content/outputs/efficientad_dcc_runs/anomaly_maps_dcc/mvtec_loco/breakfast_box/test",
  "final_image_auc_base": 67.98141221806642,
  "final_image_auc_dcc": 68.25909554573275,
  "dcc_enable": true,
  "dcc_k": 128,
  "dcc_pool": 2,
  "dcc_weight": 0.2
}
Ln 1, Col 1 100% Unix (LF) UTF-8

base_final_metrics_loco.json - Notepad
File Edit Format View Help
{
  "dataset": "mvtec_loco",
  "subdataset": "breakfast_box",
  "model_size": "medium",
  "train_steps": 1000,
  "final_image_auc": 67.92474215119574,
  "tb_dir": "/content/outputs/efficientad_runs/trainings/mvtec_loco/breakfast_box/tensorboard",
  "train_output_dir": "/content/outputs/efficientad_runs/trainings/mvtec_loco/breakfast_box",
  "test_output_dir":
"/content/outputs/efficientad_runs/anomaly_maps/mvtec_loco/breakfast_box/test",
  "pretrain_penalty": true
}
Ln 1, Col 1 100% Unix (LF) UTF-8
```



1. https://openaccess.thecvf.com/content/WACV2024/papers/Batzner_EfficientAD_Accurate_Visual_Anomaly_Detection_at_Millisecond-Level_Latencies_WACV_2024_paper.pdf
2. https://openaccess.thecvf.com/content/CVPR2022/papers/Roth_Towards_Total_Recall_in_Industrial_Anomaly_Detection_CVPR_2022_paperhttps://arxiv.org/pdf/2202.08871

با تشکر از توجه شما

Aminkianiworkeng@gmail.com
<https://github.com/M-Amin-Kiani/>

EfficientAD: Accurate Visual Anomaly Detection at Millisecond-Level Latencies

Kilian Batzner¹ Lars Heckler^{1,2} Rebecca König¹
¹MVtec Software GmbH, ²Technical University of Munich
{kilian.batzner, lars.heckler, rebecca.koenig}@mvtec.com

Abstract

Detecting anomalies in images is an important task, especially in real-time computer vision applications. In this work, we focus on computational efficiency and propose a lightweight feature extractor that processes an image in less than a millisecond on a modern GPU. We then use a student-teacher approach to detect anomalous features. We train a student network to predict the extracted features of normal, i.e., anomaly-free training images. The detection of anomalies at test time is enabled by the student failing to predict their features. We propose a training loss that hinders the student from imitating the teacher feature extractor beyond the normal images. It allows us to drastically reduce the computational cost of the student-teacher model, while improving the detection of anomalous features. We furthermore address the detection of challenging logical anomalies that involve invalid combinations of normal local features, for example, a wrong ordering of objects. We detect these anomalies by efficiently incorporating an autoencoder that analyzes images globally. We evaluate our method, called EfficientAD, on 32 detectors from three industrial anomaly detection dataset collections. EfficientAD sets new standards for both the detection and the localization of anomalies. At a latency of two milliseconds and a throughput of six hundred images per second, it enables a fast handling of anomalies. Together with its low error rate, this makes it an economical solution for real-world applications and a fruitful basis for future research.

1. Introduction

In the past years, deep learning methods have continued to improve the state of the art across a wide range of computer vision applications. This progress has been accompanied by advances in making neural network architectures faster and more efficient [43, 59, 61, 63]. Modern classification architectures, for example, focus on characteristics




Figure 1. Anomaly detection performance vs. latency per image on an NVIDIA RTX A6000 GPU. Each AU-ROC value is an average of the image-level detection AU-ROC values on the MVTEC AD [7, 9], VISA [60], and MVTEC LOCO [5] dataset collections.

computational requirements remain suitable for real-world applications. The field of visual anomaly detection has also seen rapid progress in the recent past, especially on industrial anomaly detection benchmarks [7, 9, 47, 50]. State-of-the-art anomaly detection methods, however, often sacrifice computational efficiency for an increased anomaly detection performance. Common techniques are ensembling, the use of large backbones, and increasing the input image resolution up to 768×768 pixels.

Real-world anomaly detection applications frequently put constraints on the computational requirements of a method. There are cases where detecting an anomaly too late can cause substantial economic damage, such as metal objects in a crop field entering the interior of a combine harvester. In other cases, even human health is at risk, for example, if a limb of a machine operator approaches a blade. Furthermore, industrial settings commonly involve strict runtime limits caused by high production rates [51]. Not adhering to these limits would decrease the production rate of the respective application and thus its economic viability. It is therefore essential to pay attention to the compu-